

单细胞转录组特征基因筛选实验

机器学习大作业

2025 年 12 月 23 日

目录

1 实验一：基于多模态机器学习的特征基因筛选	5
1.1 考察意义	5
1.2 实验核心目标	5
1.3 数据集信息	5
1.4 实验内容与要求	6
1.4.1 初级要求：数据清洗与基础特征筛选方法实现（30 分）	6
1.4.2 中级要求：多方法特征筛选集成（50 分）	6
1.4.3 高级要求：基于聚类一致性的创新算法设计（20 分）	7
1.5 评估与提交	7
1.5.1 统一评估框架	7
1.5.2 提交要求	8
2 实验二：基于深度自监督学习的特征基因筛选	9
2.1 考察意义	9
2.2 数据集说明	9
2.3 实验核心目标	10
2.4 实验内容与要求	10
2.4.1 初级要求：自监督预训练模型构建（30 分）	10
2.4.2 中级要求：对比学习与特征重要性评估（40 分）	10
2.4.3 高级要求：提示学习与端到端评估（30 分）	10
2.5 评估与提交	11
2.5.1 评估标准	11
2.5.2 可视化要求	11
2.5.3 提交要求	11

实验说明

实验选择

本实验提供两个难度相当的单细胞转录组特征筛选题目，学生可任选其一完成。两个实验均基于相同的乳腺癌单细胞转录组模拟数据集，但采用不同的技术路线和方法论。

实验一：基于多模态机器学习的特征基因筛选

侧重于传统统计方法、机器学习方法和深度学习方法的集成应用，遵循经典分析路线。

实验二：基于深度自监督学习的特征基因筛选

侧重于深度学习和自监督学习技术，探索人工智能在生物医学数据分析中的前沿应用。

评分结构：每个实验分为初级要求（30 分）、中级要求（50 分）和高级要求（20 分），总计 100 分。初级和中级要求为基础部分，高级要求为拓展部分。

实验背景

什么是单细胞转录组测序？

单细胞转录组测序（scRNA-seq）是一种革命性的生物技术，它能够在单个细胞水平上测量基因的表达量。与传统的批量测序不同，scRNA-seq 可以揭示细胞群体中的异质性，识别稀有细胞类型，并理解细胞状态转变的动态过程。

表达矩阵是什么？

单细胞转录组数据通常表示为**表达矩阵**，其维度为 $n \times m$ ，其中：

- n ：细胞数量（本实验：约 10,000 个细胞）
- m ：基因数量（本实验：约 15,000 个基因）
- 每个元素：表示特定细胞中特定基因的表达量（通常为经过标准化处理的计数）

乳腺癌及其亚型简介

乳腺癌是女性最常见的恶性肿瘤之一，具有高度异质性。根据分子标志物的表达，乳腺癌主要分为四种亚型：

亚型	特征描述
ER+ (Luminal A/B)	雌激素受体阳性，占乳腺癌的 60-70%，预后相对较好，对内分泌治疗敏感
HER2+	人表皮生长因子受体 2 过表达，占 15-20%，侵袭性强，但靶向治疗（如赫赛汀）有效
TN (三阴性)	雌激素受体、孕激素受体、HER2 均为阴性，占 10-15%，侵袭性最强，缺乏靶向治疗，预后最差
ER+HER2+ (双阳性)	同时表达雌激素受体和 HER2，占 5-10%，兼具两种亚型特点，需联合治疗

表 1: 乳腺癌主要亚型特征

不同亚型在基因表达模式、治疗反应和预后方面存在显著差异，因此准确识别亚型对于个性化治疗至关重要。

特征基因筛选的重要性

在高维单细胞数据中，大多数基因是噪声或不相关的。特征基因筛选的目标是：

1. **降维**：从数万个基因中筛选出数百个关键基因
2. **分类性能**：提高下游分析（如细胞亚型分类）的准确性和效率
3. **计算效率**：减少计算资源和时间消耗
4. **方法学验证**：比较不同特征筛选算法的有效性

关于模拟数据的说明

本实验使用的是乳腺癌单细胞转录组**模拟数据**，并非真实生物数据。数据中故意添加了噪声细胞（非四种标准亚型）和噪声基因（全零表达）。数据清洗是实验的重要环节，必须严格按照要求进行。由于是模拟数据，**不要求生物学意义解释**，重点关注方法学比较。

1 实验一：基于多模态机器学习的特征基因筛选

1.1 考察意义

本实验旨在通过系统比较不同方法论框架下的特征基因筛选效果，培养学生以下能力：

1. **方法掌握能力：**系统掌握统计检验、机器学习、深度学习三种方法论的特征筛选技术
2. **算法设计能力：**通过自行设计基于聚类一致性的特征筛选算法，提升数学建模和算法创新能力
3. **评估比较能力：**构建统一的评估框架，客观比较不同方法的优劣，培养科学评估思维
4. **工程实践能力：**完成从数据清洗、特征筛选到结果评估的完整数据分析流程
5. **问题解决能力：**针对模拟数据中的噪声问题，设计有效的数据清洗策略

通过本实验，学生将深入理解不同特征筛选方法的原理、适用场景和局限性，为后续的科研和工程实践奠定坚实基础。

1.2 实验核心目标

1. 系统实现并比较统计检验、机器学习、深度学习三种方法论的特征筛选效果
2. 自行设计基于聚类一致性的特征筛选算法，体现数学建模能力
3. 构建统一的评估框架，客观比较不同方法的优劣
4. 掌握单细胞模拟数据清洗的基本方法

1.3 数据集信息

乳腺癌单细胞转录组模拟数据集

项目	描述
数据格式	.h5ad (AnnData 格式)
原始细胞数量	约 10,000 个细胞
原始基因数量	约 15,000 个基因
乳腺癌亚型	TN, ER+, HER2+, ER+HER2+
数据特点	模拟数据 ，包含非四种亚型的噪声细胞和全零表达的噪声基因
数据质量	需要清洗：去除无效细胞和基因

表 2: 乳腺癌单细胞转录组模拟数据集基本信息

1.4 实验内容与要求

1.4.1 初级要求：数据清洗与基础特征筛选方法实现（30 分）

核心目标：掌握单细胞数据清洗、预处理和基础统计方法。

任务 1：数据清洗与预处理

完成数据清洗与预处理工作，具体包括：使用 scanpy 加载.h5ad 格式数据，统计原始数据的细胞数、基因数、亚型分布以及数据稀疏度。在数据清洗环节，需要只保留四种标准亚型的细胞，移除全零表达的基因以及低表达基因，同时过滤掉总表达量异常的低质量细胞。数据预处理阶段需进行归一化处理，包括 CTPM 方法和对数转换，并筛选出 500 个高变异基因。此外，要求绘制清洗前后的亚型分布对比条形图、基因表达量分布直方图，并使用 PCA 降维展示细胞分布。

任务 2：基于统计检验的特征筛选

完成基于统计检验的特征筛选任务，主要包括：使用 Wilcoxon 秩和检验识别各亚型的差异表达基因，针对每个亚型进行一对多比较，并使用 FDR 方法进行多重检验校正。要求每个亚型筛选出前 50 个差异表达基因，按 log2 Fold Change 排序，绘制火山图展示差异表达结果，并提供包含基因名、校正后 p 值、log2FC 的基因列表。

1.4.2 中级要求：多方法特征筛选集成（50 分）

核心目标：集成机器学习和深度学习方法，构建多模态特征筛选框架。

任务 3：基于机器学习的特征筛选

实现基于机器学习的特征筛选方法，包括：训练多分类随机森林模型并使用 Gini 重要性评估特征重要性，配置 XGBoost 多分类模型并使用 gain、cover 和 weight 三种重要

性类型进行评估。需要设计多方法集成策略，结合随机森林和 XGBoost 的重要性评分，通过加权集成策略筛选出前 100 个特征基因。

任务 4：基于深度学习的特征筛选

实现基于深度学习的特征筛选方法，包括：构建多层感知机分类模型并应用 Dropout、BatchNorm 等正则化技术；实现基于梯度的特征重要性评估，计算输入特征对模型输出的梯度，使用梯度绝对值或平方作为特征重要性指标。要求比较深度学习方法与机器学习方法的筛选结果重叠率，并分析不同方法的优缺点。

1.4.3 高级要求：基于聚类一致性的创新算法设计（20 分）

核心目标：自行设计数学建模方法，基于聚类一致性原理筛选特征基因。

任务 5：聚类一致性算法设计与实现

自行设计并实现基于聚类一致性的特征基因筛选算法。算法设计思想基于以下核心假设：优秀的特征基因应在不同聚类算法中稳定地展现出区分能力。具体实现时需要通过多种聚类算法验证基因的表达模式一致性，并设计评分函数结合基因表达模式与聚类稳定性。需要实现聚类一致性评分函数，使用多种聚类算法计算基因表达值的组间/组内方差比，评估基因在不同亚型中的表达特异性，并加权综合各维度得到最终一致性得分。要求将新方法与传统方法在独立验证集上比较，分析算法的时间复杂度和空间复杂度，并讨论算法的创新点和潜在改进方向。

1.5 评估与提交

1.5.1 统一评估框架

1. 评估指标

- 分类性能：准确率、F1 分数、精确率、召回率
- 特征稳定性：多次运行结果的 Jaccard 相似度

2. 评估流程

- 使用 5 折交叉验证评估分类性能
- 比较不同方法筛选的特征基因集合
- 分析特征数量与分类性能的关系

3. 可视化要求

- 绘制各方法分类性能对比柱状图
- 绘制特征重叠 Venn 图
- 绘制学习曲线（深度学习）
- 绘制基因表达热图（top 特征基因）

1.5.2 提交要求

- **实验报告（PDF 格式）**

- 实验设计与方法描述（需包含算法设计思路）
- 完整的结果分析与可视化
- 方法比较与讨论
- 创新点总结与改进方向

- **源代码**

- 完整可执行的 Python 代码
- 良好的代码结构和注释
- README 文件说明运行环境和方法

- **提交格式**

- 压缩包文件名：组长姓名 _ 实验一.zip
- 提交至指定邮箱，附小组成员信息（学号 + 姓名）

2 实验二：基于深度自监督学习的特征基因筛选

2.1 考察意义

本实验旨在探索自监督学习在特征基因筛选中的应用，培养学生以下能力：

1. **前沿技术掌握**：掌握自监督学习、对比学习、提示学习等深度学习前沿技术
2. **表征学习能力**：理解如何从无标签数据中学习有意义的特征表示
3. **少样本学习能力**：设计提示学习框架，实现在有限标签数据下的高效微调
4. **端到端建模能力**：构建完整的深度学习工作流，从数据预处理到模型评估
5. **创新应用能力**：将计算机视觉领域的先进方法迁移到生物信息学问题

通过本实验，学生将掌握深度自监督学习在生物医学数据分析中的最新应用，了解如何利用无标签数据提升特征学习效果，为处理实际生物医学数据中的标签稀缺问题提供解决方案。

2.2 数据集说明

项目	描述
主数据文件	breast_cancer_scrna_simulated.h5ad
少样本划分	few_shot_splits/ 目录下
细胞总数	10,000 个细胞
基因总数	15,000 个基因
有标签细胞	约 9,000 个（四种标准亚型）
无标签细胞	约 1,000 个（"Unknown" 亚型）

表 3: 实验二数据集配置

少样本学习划分：

- 10_percent.npy: 10% 有标签数据（约 4,750 个细胞）
- 30_percent.npy: 30% 有标签数据（约 14,250 个细胞）
- 50_percent.npy: 50% 有标签数据（约 23,750 个细胞）
- all.npy: 全部有标签数据（约 47,500 个细胞）

2.3 实验核心目标

1. 掌握自监督学习在单细胞数据分析中的应用原理
2. 实现基于对比学习和自编码器的无监督特征提取方法
3. 设计端到端的深度学习特征筛选框架
4. 理解表征学习对特征发现的增强作用
5. 设计提示学习框架，实现在少量标签数据下的高效微调

2.4 实验内容与要求

2.4.1 初级要求：自监督预训练模型构建（30 分）

核心目标：构建自编码器模型，学习单细胞数据的压缩表示。

任务 1：自编码器设计与实现

构建标准的自编码器模型，设计合适的编码器和解码器结构，实现重构损失函数并训练稳定的编码器-解码器架构，保存训练好的编码器模型用于特征提取。同时实现基因表达数据的增强方法，包括高斯噪声添加和随机掩码，并设计增强参数的可调节性。

2.4.2 中级要求：对比学习与特征重要性评估（40 分）

核心目标：实现对比学习框架，并通过注意力机制评估特征重要性。

任务 2：SimCLR 对比学习实现

实现 SimCLR 对比学习框架，包括数据增强生成正样本对、共享编码器结构、投影头将特征映射到对比空间，使用 InfoNCE 损失函数优化表征空间并设置温度参数。

任务 3：特征重要性评估模块

在预训练编码器后添加自注意力层，计算基因级注意力权重作为重要性分数，实现注意力可视化并基于注意力权重筛选前 50 个重要基因。同时实现集成梯度方法，计算输入特征对表征空间的贡献度，基于梯度重要性筛选前 50 个重要基因，并比较注意力与梯度方法筛选结果的重叠率。

2.4.3 高级要求：提示学习与端到端评估（30 分）

核心目标：设计提示学习框架，实现在少量标签数据下的高效微调，并进行全面评估。

任务 4: 提示学习框架设计

设计提示学习框架，包括冻结预训练编码器的所有参数，设计可学习的提示向量，实现提示向量与编码特征的拼接操作，添加轻量级分类头，并仅训练提示向量和分类头参数。

任务 5: 全面性能评估与解释

建立多维度评估体系，包括分类性能、聚类质量、特征稳定性和计算效率的评估。需要实现交叉验证评估分类性能，计算调整兰德指数和标准化互信息评估聚类质量，通过不同随机种子下的 Jaccard 相似度评估特征稳定性。

2.5 评估与提交

2.5.1 评估标准

1. **评估说明：** 由于所使用的数据集为虚拟数据集，因此不再考虑相关指标优劣，重点在于实现完整的工作流程；

2.5.2 可视化要求

- **学习曲线：** 预训练和微调过程中的损失变化
- **特征重要性热图：** 展示 top 特征基因的重要性分数
- **降维可视化：** UMAP/t-SNE 展示学习到的特征表示
- **注意力可视化：** 展示注意力权重在基因上的分布

2.5.3 提交要求

- **实验报告 (PDF 格式)**
 - 完整的技术路线和方法描述
 - 详细的实验结果
 - 创新点总结和未来改进方向
- **源代码**
 - 完整的 PyTorch/TensorFlow 实现
 - 模块化设计，包含数据加载、模型定义、训练、评估等模块
 - 详细的 README 说明文件

- 提交格式

- 压缩包文件名：组长姓名 _ 实验二.zip
- 提交至指定邮箱，附小组成员信息（学号 + 姓名）

通用要求与注意事项

数据清洗要点

1. 细胞过滤：

- 移除无亚型标签或标签不在四种标准亚型中的细胞
- 移除总表达量过低或过高的细胞（技术异常）

2. 基因过滤：

- 移除在所有细胞中表达量为零的基因
- 移除在少于 10 个细胞中表达的基因（低表达基因）

3. 质量控制：

- 记录清洗前后的数据维度变化
- 可视化清洗效果（亚型分布、表达量分布等）

实验环境建议

基础环境配置

```
1 # 核心数据科学库
2 numpy >= 1.21.0
3 pandas >= 1.4.0
4 scipy >= 1.8.0
5 scikit-learn >= 1.0.0
6
7 # 单细胞分析
8 scanpy >= 1.9.0
9 anndata >= 0.9.0
10
```

```
11 # 可视化
12 matplotlib >= 3.5.0
13 seaborn >= 0.11.0
```

Listing 1: 基础环境配置

实验一专用环境

```
1 # 机器学习库
2 xgboost >= 1.6.0
3
4 # 统计和可视化
5 statsmodels >= 0.13.0
6
7 # 深度学习（可选）
8 tensorflow >= 2.8.0 # 或 pytorch >= 1.11.0
```

Listing 2: 实验一环境配置

实验二专用环境

```
1 # 深度学习核心
2 torch >= 2.0.0
3
4 # 模型解释
5 captum >= 0.6.0
6
7 # GPU支持
8 CUDA >= 11.7（推荐）
```

Listing 3: 实验二环境配置

祝同学们实验顺利！